

M I N E R I A D E D A T O S

HITO Nº1

G R U P O 1 8



MOTIVACION: OUR GALAXY

01

Astronomía:

- Tecnología
- Ciencias computacionales
- Gran poder de procesamiento → Gran volumen de datos
- Minería de datos → Herramienta fundamental

02

Conceptos fundamentales:

- Estrellas, agujeros negros, galaxias, AGN's, QSO's
- Redshift
- Magnitudes ugriz

03

Proyecto basado en: Brescia et. al 2015



EXPLORACION DE DATOS: OUR DATA

01

Datos usados: Sloan Digital Sky Survey (SDSS) Data Release 10. Alrededor de 3,6M de fuentes.

Pregunta de investigación: ¿Podemos clasificar y predecir el redshift de objetos usando fotometría?

←
Galactic

EXPLORACION DE DATOS:

Datos SDSS DR 10:

	objID	RAdeg	Decdeg	umag	gmag	rmag	imag	zmag	u'mag	g'mag	r'mag	i'mag	z'mag	specID	subclass	z	qf
0	1237669697834516732	332.193566	6.213506	20.694180	20.070652	19.902487	19.833360	19.617641	20.702007	20.066208	19.903557	19.825838	19.612368	2615518058759874560	BROADLINE	0.000461	0.0
1	1237668331500929566	242.615071	9.127335	20.184590	20.125793	20.083216	20.264364	19.954805	20.170850	20.102804	20.053980	20.253532	20.000866	2844050179592579072	BROADLINE	0.000461	1.0
2	1237678859536302437	338.916923	11.483463	21.678028	21.292742	21.197329	21.170238	21.538815	21.655334	21.272352	21.143225	21.130280	21.298502	5684755593458876416	4.6062307E-4	0.000000	NaN
3	1237667730193581111	120.828351	9.728672	22.114391	21.625710	21.480595	21.595968	21.215242	22.183746	21.623096	21.470402	21.597070	21.242352	6185898695620820992	5.767762E-4	0.000000	NaN
4	1237654626786738691	116.210005	31.646465	21.893473	21.455797	21.365667	21.404415	21.234035	21.910515	21.379683	21.280743	21.330507	21.222286	5002396468775485440	5.7690655E-4	0.000000	NaN
...
3602205	1237671686933971079	160.202834	79.700491	20.314724	20.115656	20.120022	19.846950	19.761147	20.332558	20.112700	20.103870	19.819887	19.801836		1	NaN	NaN
3602206	1237671686933971158	160.428454	79.625446	18.853277	18.651420	18.550852	18.575981	18.617682	18.875570	18.652070	18.556755	18.574717	18.629831		1	NaN	NaN
3602207	1237671686934037235	160.882926	79.442167	22.051360	21.963966	21.302395	20.819840	20.185960	21.975136	21.741077	21.046968	20.553333	20.002817		0	NaN	NaN
3602208	1237671686934037238	160.816211	79.432448	22.432056	22.067238	21.406551	21.063618	21.624708	22.473427	22.052916	21.424982	21.057661	21.563576		0	NaN	NaN
3602209	1237671686934036581	160.850917	79.513393	24.374573	20.937517	20.529442	20.632936	20.399504	24.458103	20.931923	20.535520	20.626488	20.409494		0	NaN	NaN


3602210 rows × 17 columns

EXPLORACION DE DATOS: OUR DATA

Filtro realizado:

- 02
- Subclase válida (AGN, STARBURST, BROADLINE, etc.)
 - $Qf = 1 \rightarrow 74k$ fuentes clasificadas de alta calidad
 - Quedamos con cerca de 70mil datos

EXPLORACION DE DATOS:



EXPLORACION DE DATOS:


```
1 df["subclass"].value_counts()
```




subclass	count
BROADLINE	71082
STARBURST_BROADLINE	2675
STARFORMING_BROADLINE	88
AGN_BROADLINE	44
STARBURST	36
AGN	28
STARFORMING	10

Name: count, dtype: int64

EXPLORACIÓN DE DATOS




PREGUNTAS Y PROBLEMAS: OUTER SPACE



Problemas:

- Desbalance de clases
- ¿Over o under-sampling?
- Inyección de datos externos



PROPUESTA METODOLÓGICA

01

MÉTODO DEL PAPER:

- MULTI LAYER PERCEPTRON WITH QUASI-NEWTON ALGORITHM (MLPQN): 500K DATOS CONDENSADOS

02

PROPONEMOS MEJORAR LOS RESULTADOS:

- ACTUALIZAR DATOS (DR19 O AL MENOS SUPERIOR A DR10)
- DIFERENTES FORMAS DE CLASIFICACIÓN
- MANIPULACIÓN DE LOS DATOS
- OVER Y UNDERSAMPLING
- INYECCIÓN DE DATOS



MUCHAS
GRACIAS

